Übungsblatt 8: KI-Beschleuniger & Edge AI

Mikrocomputertechnik 3 · 32 Orientierungspunkte · ca. 60–75 Minuten

Musterlösung

Aufgabe 1: Drei Ausgänge aus zwei Eingängen (5 Punkte)

Dense-Schicht $y = Wx + b$, keine Aktivierungsfunktion:

$$W = \begin{bmatrix} 2 & -1 \\ -3 & 4 \\ 1 & 2 \end{bmatrix}, \quad x = \begin{bmatrix} 3 \\ -2 \end{bmatrix}, \quad b = \begin{bmatrix} -1 \\ 2 \\ 0 \end{bmatrix}.$$

1. Berechnen Sie alle drei Ausgänge. (2 P)
2. Zählen Sie Parameter und produktbezogene MACs. (1 P)
3. Gewichte und Eingaben: Int8, Bias: Int32. Zählen Sie gespeicherte Bytes, anschließend zusätzlich drei Int8-Ausgaben. Ist dies die gesamte Arena? (2 P)

Musterlösung 1

1. $y_0 = 6 + 2 - 1 = 7$, $y_1 = -9 - 8 + 2 = -15$, $y_2 = 3 - 4 = -1$. (2 P)
2. Sechs Gewichte, drei Biaswerte: neun Parameter; sechs MACs. (1 P)
3. $6 + 12 + 2 = 20$ Byte, mit Ausgaben 23 Byte. Metadaten, Ausrichtung und temporäre Arbeitsbereiche fehlen. (2 P)

Aufgabe 2: Mehr innere Produkte, andere Roofline (5 Punkte)

Eine MAC zählt zwei Operationen, Operanden vier Byte. Grenze: externer Speicher zum lokalen Puffer; zunächst nur Eingangstransfers. Peak zwölf Operationen/Takt, Bandbreite sechs Byte/Takt. $P \leq \min(P_{\text{peak}}, BI)$.

1. Bestimmen Sie Obergrenzen bei Intensität 0,5 und zwei Operationen/Byte sowie den Knick. (2 P)
2. Ein 2×3-mal-3×2-Matrixprodukt hat zwölf MACs. Naiv werden beide Operanden je MAC neu geladen, mit Wiederverwendung jeder der zwölf verschiedenen Eingangswerte einmal. Bestimmen Sie Bytezahlen und Intensitäten; danach zusätzlich vier Ausgaben zu je vier Byte ohne altes C einzulesen. (2 P)
3. Peak steigt auf 24, Bandbreite bleibt sechs: Ändert sich die Grenze bei Intensität 0,5? (1 P)

Musterlösung 2

1. Drei und zwölf Operationen/Takt, Knick bei zwei Operationen/Byte. (2 P)
2. 24 Operationen: naiv 96 Byte, Intensität 0,25; wiederverwendet 48 Byte, Intensität 0,5. Mit 16 Ausgabebytes: 112 beziehungsweise 64 Byte, Intensitäten $3/14 \approx 0{,}2143$ und 0,375. Diese letzten Werte verwenden eine erweiterte Transfergrenze. (2 P)
3. Nein, $\min(24, 6 \cdot 0{,}5) = 3$. (1 P)

Aufgabe 3: Andere Vektorgruppen und längere Latenz (6 Punkte)

RVV: VLEN Registerbits, SEW Elementbits, LMUL Gruppengröße; VLMAX = LMUL · VLEN/SEW. Für unterstützte Konfigurationen gilt: AVL bis VLMAX liefert genau AVL; AVL ab zweimal VLMAX liefert VLMAX; dazwischen liegt VL zwischen $\lceil AVL/2 \rceil$ und VLMAX.

1. VLEN 256, SEW 16, LMUL zwei: VLMAX? Folgt daraus die Lanezahl? (1 P)
2. Separat VLMAX 16, AVL 26: Prüfen Sie $16 + 10$, $14 + 12$, $13 + 13$, $12 + 14$. Welche Byteinkremente gelten bei $14 + 12$ für Zwei-Byte-Elemente? (2 P)
3. Wie viele Iterationen benötigt ein Array mit 250 Elementen bei VLMAX 16? (1 P)
4. Sechs unabhängige Produkte starten in Takten eins bis sechs, Latenz drei. Zugehörige unabhängige Additionen: Latenz zwei, Startabstand eins. Mit Chaining starten sie frühestens im Takt nach ihrem Produkt; ohne erst nach allen Produkten. Wann endet das letzte Ergebnis jeweils? Ist dies eine Befehlssatzgarantie? (2 P)

Musterlösung 3

1. 32 Elemente, keine Aussage über physische Lanes. (1 P)
2. Erste VL muss 13 bis 16 sein: die ersten drei Folgen sind zulässig, die vierte nicht. Byteinkremente 28 und 24. (2 P)
3. Vierzehn volle Iterationen verarbeiten 224 Elemente; Rest 26 braucht zwei, zusammen sechzehn Iterationen. (1 P)
4. Produkte enden drei bis acht. Chaining: Additionen starten vier bis neun, enden fünf bis zehn. Ohne: Starts neun bis vierzehn, Enden zehn bis fünfzehn. Letztes Ende zehn beziehungsweise fünfzehn, nur im gegebenen Modell. (2 P)

Aufgabe 4: Ein längeres Tile im systolischen Array (6 Punkte)

$$A = \begin{bmatrix} 2 & 1 & -1 \\ 3 & 0 & 2 \end{bmatrix}, \quad B = \begin{bmatrix} 1 & 4 \\ -2 & 3 \\ 5 & -1 \end{bmatrix}, \quad C = AB.$$

Vier Output-Stationary-Zellen, anfangs Summen null; eine gültige MAC je Zelle und Takt. A wandert rechts, B unten, je einen Nachbarn pro Takt. Einspeisung links in $1 + k + i$, oben in $1 + k + j$; $i, j \in \{0, 1\}$, $k \in \{0, 1, 2\}$. Keine Vorlade- oder Auslesezeit im Fenster.

1. Tragen Sie alle vier Teilsummen nach jedem der fünf Takte ein; markieren Sie deren letzte gültige MAC. (3 P)
2. Welche Paare erreichen C11 in welchen Takten? Zählt das Produkt mit null als gültige MAC? (1 P)
3. Bestimmen Sie zeitliche Auslastung über fünf Takte. Dasselbe Tile belegt allein vier Zellen eines 4×4-Arrays: zeitliche Auslastung und räumliche Belegung? Sind die Ergebnisse bereits ausgelesen? (2 P)

Musterlösung 4

Takt	C00	C01	C10	C11	gültige MACs
1	2	0	0	0	1
2	0	8	3	0	3
3	−5 fertig	11	3	12	4
4	−5	12 fertig	13 fertig	12	3
5	−5	12	13	10 fertig	1

Tabelle 3 P. C11 erhält $(3, 4)$ in drei, $(0, 3)$ in vier, $(2, -1)$ in fünf. Numerische null ist kein ungültiger Platz. (1 P) Zwölf MACs: $12/(4 \cdot 5) = 60\,\%$; im größeren Array 15 Prozent zeitlich, 25 Prozent räumlich. Readout benötigt weiterhin einen eigenen Weg. (2 P)

Aufgabe 5: Negative Werte quantisieren (6 Punkte)

Int8-Bereich $[-128, 127]$; $q = \text{clip}(\text{round}(r/s) + z)$, $\hat{r} = s(q - z)$; halbe Werte werden weg von null gerundet.

1. Skala 0,2, Nullpunkt null: Code, Rückwert und absoluter Fehler für $r = -1{,}37$ und $r = -30$? Welche Fehlerarten liegen vor? (2 P)
2. Welcher Code repräsentiert reale null bei Nullpunkt fünf? (1 P)
3. Separat $q_x = [7, -3], z_x = 1, s_x = 0{,}25$; $q_w = [-2, 3], z_w = 0, s_w = 0{,}1$; Biascode vier mit Skala $s_x s_w$. Berechnen Sie Akkumulation und Realwert. Requantisieren Sie mit $s_y = 0{,}08, z_y = 3$. (2 P)
4. Vergleichen Sie 180000 reine Gewichte in Float32 und Int8. Gilt deren prozentuale Ersparnis für die ganze Modelldatei und Arena? (1 P)

Musterlösung 5

1. $-1{,}37$: Code -7, Rückwert $-1{,}4$, Fehler 0,03 durch Rundung. -30: Code -128, Rückwert $-25{,}6$, Fehler 4,4 durch Sättigung. (2 P)
2. Code fünf. (1 P)
3. Korrigierte Eingaben sechs und -4. $a = 6(-2) + (-4)3 + 4 = -20$, Realwert $-20 \cdot 0{,}025 = -0{,}5$. Ausgangscode $\text{round}(-6{,}25) + 3 = -3$, Rückwert $-0{,}48$, Fehler 0,02. (2 P)
4. 720000 und 180000 Byte, 75 Prozent nur für Gewichtbytes. (1 P)

Aufgabe 6: Andere Plattform und anderes Sensorfenster (4 Punkte)

1. 192 KiB Flash: Firmware 52 KiB, vollständiges Modell 36 KiB. 48 KiB SRAM: Arena 18 KiB, Quellfenster 1600 Byte, Stack sieben KiB, andere Daten fünf KiB. Zieltensor bereits in der Arena. Bestimmen Sie beide freien Budgets. (1 P)
2. Fenster aus 200 Zeitpunkten mit zwei Kanälen: Float32-Quellgröße und Int8-Zielgröße? Warum hilft sizeof eines Zeigers nicht? (1 P)
3. Lokale Arena/Interpreter werden nach Setup-Rückkehr weiter benutzt; nach einem Inferenzfehler wird der alte Ausgang als neue Entscheidung verwendet. Benennen Sie beide Korrekturen. (1 P)
4. Serielle Zeiten: Vorbereitung 1,5 ms, Dense zwölf ms, andere Operatoren 2,5 ms, Nachbereitung 0,5 ms. Beschleunigt: zusätzlich 0,75 ms Kopie, Dense zwei ms. Bestimmen Sie Gesamtzeiten, Dense- und Gesamtfaktor. (1 P)

Musterlösung 6

1. Flash 104 KiB frei. SRAM $48 - 18 - 1600/1024 - 7 - 5 = 16{,}4375$ KiB frei. (1 P)
2. 400 Elemente, 1600 Byte Quelle, 400 Byte Ziel; Zeigergröße zählt keine Elemente. (1 P)
3. Ausreichende Lebensdauer aller Objekte; Status prüfen und nur erfolgreiche aktuelle Ausgaben verwenden. (1 P)
4. CPU 16,5 ms, Beschleuniger 7,25 ms; Densefaktor sechs, Gesamtfaktor $66/29 \approx 2{,}276$. (1 P)

Optional: am Rechner prüfen

Ergänzen Sie `src/lab08_dense.c` um eine eigene 3×2-Dense-Funktion für Aufgabe 1 und einen 2×3-mal-3×2-Matrixtest für Aufgabe 4. Erwartete Ergebnisse stehen in den Papierlösungen. Prüfen Sie zusätzlich die neuen negativen Quantisierungsfälle; die vorhandenen Folien-Testwerte reichen nicht.