Übungsblatt 8: KI-Beschleuniger & Edge AI

Mikrocomputertechnik 3 · Datenfluss, Vektorlängen und Speicherplanung auf Papier

Ziel und Arbeitsweise

Die sechs Pflichtaufgaben sind vollständig auf Papier lösbar. Geben Sie Rechenweg, Einheiten und Zählgrenze an. Alle Architekturzeiten und Speicherbudgets sind Lehrannahmen.

Bearbeitungszeit: etwa 60–75 Minuten selbstständig. **Orientierungspunkte:** 32. Im Unterricht: Aufgaben 1–2 (10 min), Aufgabe 3 (15 min), Aufgabe 4 (15 min), Aufgaben 5–6 (15 min). Lösungsbesprechungen sind in die Vorlesungsphasen eingeplant.

MAC heißt Multiply-Accumulate und zählt hier zwei Operationen. Int8: 1 B, Int32/Float32: 4 B je Element. KiB = 1024 B, MB = 10^6 B.

Aufgabe 1: Dense-Schicht und Datenbudget (5 Punkte)

Eine Dense-Schicht, vollständig verbundene Schicht, berechnet $y = Wx + b$. Eine anschließende Aktivierungsfunktion ist ausgeblendet.

$$W = \begin{bmatrix} 1 & 2 & 3 \\ 0 & -1 & 4 \end{bmatrix}, \quad x = \begin{bmatrix} 2 \\ 1 \\ 3 \end{bmatrix}, \quad b = \begin{bmatrix} 1 \\ -2 \end{bmatrix}$$

1. Berechnen Sie beide Ausgänge einschließlich Zwischenrechnungen. (2 P)
2. Zählen Sie trainierbare Parameter und produktbezogene MACs. Warum sind diese Zahlen verschieden? (1 P)
3. Gewichte und Eingaben liegen als Int8, Biaswerte als Int32 vor. Wie viele gespeicherte Byte benötigen W, b und x zusammen? Wie verändert sich diese Summe, wenn zwei Int8-Ausgänge hinzukommen? Ist dies bereits die Größe der Modelldatei oder der Arena? (2 P)

Ihre Ausgänge, Zählung und Bytebilanz:

Aufgabe 2: Roofline und Wiederverwendung (5 Punkte)

Lehrmodell R betrachtet zunächst nur Operandenverkehr vom externen Speicher zum lokalen Puffer. Jede MAC zählt zwei Operationen, jeder Operand vier Byte. Bias und Ausgabeschreiben sind zunächst ausgeschlossen. Rechenpeak $P_{\text{peak}} = 8$ Ops/Takt, Bandbreite $B = 8$ Byte/Takt. Roofline ist das Modell $P \leq \min(P_{\text{peak}}, BI)$, I die Intensität in Ops/Byte.

1. Berechnen Sie die ideale Obergrenze für $I = 0{,}25$ und $I = 0{,}5$. Wo liegt der Knick, und welche Grenze ist an beiden Punkten enger? (2 P)
2. Ein 2×2-Produkt $C = AB$ benötigt acht MACs. Naiv lädt jede MAC beide Operanden neu. Mit lokalem Halten wird jeder der acht verschiedenen Eingangswerte einmal geladen. Berechnen Sie beide Eingangsbytezahlen und Intensitäten. Nun werden zusätzlich vier Ausgaben zu je vier Byte geschrieben, ohne vorher ein altes C zu lesen. Wie ändern sich Bytezahlen und Intensitäten? (2 P)
3. Der Rechenpeak wird auf 16 Ops/Takt erhöht, die Bandbreite bleibt 8 Byte/Takt. Wird bei der ursprünglichen Eingangsintensität 0,25 die Grenze größer? Begründen Sie. (1 P)

Ihre Obergrenzen und Transferbilanz:

Aufgabe 3: Vektorlänge und Zeitmodell (6 Punkte)

RVV bedeutet RISC-V Vector Extension. VLEN ist die Registerbreite in Bit, SEW die Elementbreite, LMUL die Registergruppengröße und VLMAX die Elementkapazität. AVL ist die angeforderte Restzahl, VL die aktive zurückgegebene Länge.

Es gelten die RVV-1.0-Regeln für eine unterstützte Konfiguration: Bei AVL $\leq$ VLMAX ist VL exakt AVL, bei AVL $\geq$ 2VLMAX exakt VLMAX, dazwischen ein Integer von $\lceil \text{AVL}/2 \rceil$ bis VLMAX.

1. VLEN = 128 Bit, SEW = 32 Bit, LMUL = 1. Bestimmen Sie VLMAX. Folgt daraus dieselbe Zahl physischer Rechen-Lanes? (1 P)
2. Separates Beispiel: VLMAX = 32, AVL = 40. Prüfen Sie die Folgen $32+8$, $24+16$, $20+20$, $16+24$. Geben Sie für $24+16$ beide Zeigerinkremente bei Vier-Byte-Elementen an. (2 P)
3. Wie viele Iterationen verarbeitet ein Array mit 1000 Elementen bei dieser Kapazität? Begründen Sie auch die letzten Abschnitte. (1 P)
4. Ein eigenes Chaining-Modell startet vier unabhängige Multiplikationen in Takten eins bis vier. Latenz zwei, Ergebnis jeweils am Taktende. Die zugehörigen unabhängigen Additionen haben Latenz eins und Startabstand eins. Mit Weitergabe darf jede Addition im Takt nach ihrem Produkt beginnen; ohne Weitergabe erst nach Fertigstellung aller vier Produkte. Wann endet das letzte Ergebnis in beiden Fällen? Ist das eine RVV-Zeitgarantie? (2 P)

Ihre Längenfolgen und Zeitachse:

Aufgabe 4: Systolische Teilsummen (6 Punkte)

$$A = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}, \quad B = \begin{bmatrix} 5 & 6 \\ 7 & 8 \end{bmatrix}, \quad C = AB$$

Vier Zellen C_{ij} halten ihre Ausgabesumme lokal (Output-Stationary). Anfangs sind alle Summen null. Eine gültige MAC wird im aktuellen Takt fertig. A wandert je Takt eine Zelle rechts, B eine unten. Indizes i, j, k beginnen bei null. A_{ik} wird links in Takt $1 + k + i$ eingespeist, B_{kj} oben in Takt $1 + k + j$. Vorladen und Auslesen sind nicht Teil dieses Zeitfensters.

1. Tragen Sie die vier Teilsummen nach jedem Takt ein. Markieren Sie deren letzte gültige MAC. (3 P)
2. Welche beiden Paare erreichen C_{11} in welchen Takten? Warum ist die Summe nicht schon in Takt zwei fertig? (1 P)
3. Berechnen Sie die mittlere Auslastung über vier Takte im 2×2-Array. Dasselbe Tile läuft nun isoliert in vier Zellen eines 4×4-Arrays, alle anderen bleiben leer. Berechnen Sie zeitliche Auslastung und räumliche Belegung. Ist interne Fertigstellung bereits Readout? (2 P)

Taktende	C_{00}	C_{01}	C_{10}	C_{11}
1				
2				
3				
4				

Ihre Begründung und Auslastungsrechnung:

Aufgabe 5: Quantisierung und Zahlenformate (6 Punkte)

Int8 hat Bereich $[-128, 127]$. Wir verwenden $q = \text{clip}(\text{round}(r/s) + z)$ und $\hat{r} = s(q - z)$. $s > 0$ ist die Skala, z der ganzzahlige Nullpunkt. Rundung: nächster Integer, exakte Halbfälle weg von null.

1. Mit $s = 0{,}1$, $z = 0$: Bestimmen Sie Code, Rückwert und absoluten Fehler für $r = 1{,}24$ und $r = 20$. Welche Fehlerart liegt jeweils vor? (2 P)
2. Mit $z = -3$: Welcher Code repräsentiert reale Null? Begründen Sie. (1 P)
3. Separates Skalarprodukt: $q_x = [12, -4]$, $z_x = -3$, $s_x = 0{,}1$, $q_w = [2, 3]$, $z_w = 0$, $s_w = 0{,}2$. Biascode $q_b = 5$ hat Skala $s_x s_w$ und Nullpunkt null. Bestimmen Sie die korrigierte Integerakkumulation und den realen Rückwert. Quantisieren Sie diesen mit $s_y = 0{,}05$, $z_y = -2$ erneut. (2 P)
4. 250 000 reine Gewichte wechseln von Float32 zu Int8. Berechnen Sie beide Bytezahlen und die prozentuale Ersparnis. Gilt sie auch für komplette Modelldatei und Arena? (1 P)

Ihre Codes, Fehler und breite Produktsumme:

Aufgabe 6: Firmware als Gesamtsystem (4 Punkte)

CPU bedeutet Central Processing Unit, Prozessor. SRAM ist Static Random Access Memory, statischer Arbeitsspeicher. Flash ist nichtflüchtiger Speicher, die Arena ein Tensor-Arbeitsbereich.

1. Fiktive Plattform: 128 KiB Flash, 32 KiB SRAM. Firmware 40 KiB, vollständige Modelldatei 24 KiB liegen im Flash. SRAM: Arena 12 KiB, Float-Quellfenster 1,5 KiB, Stackreserve 6 KiB, übrige Daten 4 KiB. Der Int8-Eingabetensor liegt schon in der Arena. Bestimmen Sie beide freien Restbudgets. (1 P)
2. Das Fenster enthält 128 Zeitpunkte mit je drei Achsen. Bestimmen Sie Elementzahl, Float32-Quellbytes und Int8-Zielbytes. Warum liefert `sizeof` eines Zeigers nicht diese Quellgröße? (1 P)
3. Eine Setup-Funktion erzeugt Arena und Interpreter als lokale Objekte und kehrt zurück. Eine spätere Run-Funktion verwendet sie weiter. Zusätzlich liest sie nach einem fehlgeschlagenen `Invoke()` den alten Ausgang als neue Wahrscheinlichkeit. Nennen Sie beide Fehler und die nötigen Korrekturen. (1 P)
4. Serielle Lehrzeiten: CPU-Pfad Vorverarbeitung 2 ms, Dense-Rechnung 10 ms, übrige Operatoren 3 ms, Nachverarbeitung 1 ms. Beschleunigerpfad: zusätzlich Kopie 1 ms, Dense nur 1 ms, alle übrigen Phasen unverändert. Bestimmen Sie Gesamtzeiten, Teilfaktor und Gesamtfaktor. (1 P)

Ihre Budgets, Fehleranalyse und Zeitbilanz:

Optional: Zahlenbeispiele auf dem Host prüfen

Die Datei `src/lab08_dense.c` enthält ein vollständiges C-Programm. Sie prüft die Dense-Ausgänge, Matrixprodukte, Quantisierung und Fehlerfälle. Sie benötigt weder Modellblob noch TensorFlow Micro oder Renode. Vom Repository-Hauptordner aus:

```
gcc -std=c11 -O2 -Wall -Wextra -Werror -pedantic \
    labs/src/lab08_dense.c -lm -o /tmp/lab08_dense
/tmp/lab08_dense
```

Erwartete Ausgabe:

```
Dense: 14 9
Matrix: 19 22 43 50
Quantisierung: 12 127 -128
Alle Prueffaelle bestanden.
```

1. Lesen Sie zuerst die Verträge der beiden Hilfsfunktionen. Warum wird vor dem schmalen Cast begrenzt beziehungsweise der Bereich geprüft?
2. Vergleichen Sie die zurückgerechneten Werte mit Ihren Papierlösungen.
3. Prüfen Sie optional mit `-fsanitize=address,undefined`, `-O1` und `-g`. Welche Fehlerarten kann dieser Lauf prüfen, und welche Systemaussagen fehlen weiterhin?