

07 · Moderne CPU-Architekturen

Mikrocomputertechnik 3 · Von Pipelining-Limits über Out-of-Order zur Branch Prediction

Prof. Dr.-Ing. Daniel Klünder

Folie

1 / 67

Willkommen zu Block 7!

- Willkommen zur siebten Vorlesung in Mikrocomputertechnik 3
- Bisher: RAM, Caches, Interrupts, Busse, DMA — das SoC ist ausgestattet
- Peripherie und Transfers können autonom laufen; der Engpass wandert zurück zum Kern
- Heute: wie High-End-CPU's intern mehr Rechenleistung aus demselben Takt holen

MCT1: 5-Stufen-CPU

MCT3: SoC-Peripherie

Heute: High-End-Kern

Notizen

Caches und DMA haben externe Engpässe entschärft. Zurück zum Prozessorkern: Warum reicht die MCT1-Pipeline für Desktop-/Smartphone-CPU's nicht?

Folie

2 / 67

Anknüpfung: DMA-Labor

Kurz-Recap aus Block 6 (Vertiefung im Übungsblatt):

- DMA kopiert Arrays autonom; Polling blockiert die CPU stark
- Ein Heartbeat aus `main()` kann weiterlaufen. Das beweist keine Last von null
- Bus-Mastering und Cycle Stealing: DMA teilt sich den Bus mit der CPU
- Folge: weniger ALU-Zeit für stupides Kopieren — mehr Zeit für echte Berechnung

```
/* Konzept - Adressen/Bits fiktiv bzw. Datenblatt */
DMA_CH1->SRC_ADDR = (uint32_t)text_array;
DMA_CH1->DST_ADDR = (uint32_t)&UART_TX;
DMA_CH1->CONTROL = DMA_ENABLE; /* fiktiv, kein blindes |= */
```

Notizen

DMA befreit von Kopierarbeit. Als Nächstes: Wie schnell rechnet die CPU selbst auf Befehlsebene?

Folie

3/67

Zurück in die CPU

- Fokus: Ausführungsgeschwindigkeit im Kern
- Weg von Systembus, MMIO und Peripherie-IRQs
- Rein: Pipeline, ALU, Assembler auf Befehlsebene
- Metriken und Hardware-Parallelität innerhalb eines Kerns


Notizen

Alles außerhalb des L1 blenden wir didaktisch aus — Takte, Gatter, Instruktionsstrom.

Refresher MCT1: 5-Stufen-Pipeline

Skalares 5-Stufen-Modell. Farbe = Instruktion, nicht Stufe.

Fuenf unabhängige ALU-Befehle. Ohne Stall: $5 \times 5 - 1 = 9$ Takte, $CPI = 9/5 = 1,8$.



Stationär ab Takt 5: ein WB je Takt. Davor Füllung, danach Leerung.

Ein RAW-Stall ohne Forwarding zwischen I1 und I2: +1 Takt, 10 Takte, $CPI = 2,0$.

$IPC = \text{retired ISA-Befehle} / \text{Takte des Fensters} = 5/9$. Nicht aus einem einzelnen WB schließen.

$CPI = 1/IPC$ nur fuer denselben Zeitraum und dieselbe Zaehlbasis.

$T = N \cdot CPI / f$ gilt bei konstanter Frequenz. Ein Compiler kann N ändern.

Micro-Ops zaehlen hier nicht als ISA-IPC.

Abbildung 1: Fünf ALU-Befehle, neun Takte, $CPI = 1,8$. Ein Stall ohne Forwarding macht zehn Takte.

Klassische RISC-Pipeline (Harris/Harris):

Stufe	Name	Aufgabe
IF	Instruction Fetch	Befehl holen
ID	Decode	Dekodieren, Register lesen
EX	Execute	ALU
MEM	Memory	Datenspeicher
WB	Write Back	Ergebnis ins Registerfile

Nach dem Füllen strebt der Durchsatz gegen ein Retire je Takt. Fünf Befehle brauchen im Modell ohne Stall $N + k - 1 = 9$ Takte, mittleres $CPI = 1,8$.

Notizen

Stand MCT1: Fließband mit fünf Stufen — Grundlage für alles Weitere heute.

Metriken: IPC und CPI

- IPC: retired ISA-Instruktionen pro Core-Takt im betrachteten Fenster
- Execution-Completion und Retire können in verschiedenen Takten liegen
- Micro-Ops sind keine ISA-IPC
- CPI = Takte / retired Instruktionen. CPI und IPC sind nur dann Kehrwerte
- Laufzeit bei konstanter Frequenz f im selben Fenster:

$$T = N \times \text{CPI} / f$$

Notizen

Ein Compiler kann N ändern. Höheres IPC allein verkürzt die Laufzeit nicht. Mittelwerte verschiedener Läufe nicht ungewichtet invertieren. Kurze Sequenzen enthalten Füllung und Leerung.

Limit der skalaren Pipeline

- Ideal ohne Stalls/Hazards/Misses: $\text{IPC} = 1$, $\text{CPI} = 1$
- Eine skalare Ein-Issue-Pipeline: strukturell kein $\text{CPI} < 1$
- Ein Pfad $\rightarrow$ Befehle im Gänsemarsch
- Realität oft schlechter ($\text{CPI} > 1$) durch Bubbles und Hazards

Notizen

Mauer der MCT1-Architektur: IPC höchstens 1 im Ideal — oft darunter.

Die Taktraten-Mauer (Power Wall)

- Idee der 2000er: Frequenz massiv erhöhen (GHz-Wettrennen)
- Vereinfacht $P_{dyn} \approx \alpha C V^2 f$. Leckleistung ist davon getrennt
- Keine feste Frequenzgrenze aus dieser Formel. Breitere Kerne brauchen mehr Ports, Scheduler und Bypass
- CPI verbessern ist ein Weg, kein kostenloser Ersatz für Takt

Notizen

Pentium-4-Ära: Hoffnung auf extrem hohe GHz — Physik und Kühlung setzen Grenzen.

Folie

8/67

Die Leitfrage des Tages

Vier unabhängige ALU-Befehle. ALU-Latenz 1. Füllung gehört zum Fenster.

Skalar: Issue und Retire höchstens 1. Fenster 5 Takte, IPC = $4/5 = 0,8$.



Zweifach: Issue und Retire höchstens 2. Fenster 3 Takte, IPC = $4/3 \approx 1,33$.



Takt 2 retirierte zwei Befehle. Das mittlere IPC des Fensters ist nicht 2.

Nachhaltig mehrere Retires sind etwas anderes als ein einzelner Abschlussburst.

Superskalar heisst Multiple Issue, nicht automatisch Out-of-Order.

Drei Units garantieren weder drei passende Befehle noch IPC 3.

Annahme: keine Abhängigkeit, keine Cache-Misses, Retire im Takt nach dem Issue.

P_{dyn} ungefähr $\alpha \cdot C \cdot V^2 \cdot f$. Leckleistung ist ein eigener Term. Breite ist nicht kostenlos.

Abbildung 2: Skalar $4/5 = 0,8$. Zweifach $4/3 \approx 1,33$. Ein Doppeltakt ist nicht das mittlere IPC.

- Taktfrequenz: physikalisch begrenzt
- Skalare Pipeline: Ideal $CPI = 1$ (mit Stalls oft > 1)
- Wie kann der Kern langfristig mehr als eine ISA-Instruktion je Takt retieren?
- Antwort: Parallelität *innerhalb* des Kerns (ILP ausnutzen)

Das Zeitdiagramm oben ersetzt die Ein-Takt-Skizze. IPC wird über das ganze Fenster gerechnet.

Notizen

Nicht schneller takten — breiter und smarter schedulen.

Folie

9/67

Agenda

1. Grenzen des Pipelining
2. ILP und Superskalarität
3. Out-of-Order Execution
4. Branch Prediction
5. Spekulation und Security (Spectre/Meltdown)
6. Labor-Ausblick (Compiler / Godbolt)

Notizen

Von skalarer Pipeline über OoO und Prediction bis Spekulation und Compiler.

Folie

10/67

Lernziele Block 7

- Skalare vs. superskalare Pipeline erklären
- Datenabhängigkeiten RAW, WAW, WAR unterscheiden
- Register Renaming und Reorder Buffer (ROB) einordnen
- Warum Branches tiefe Pipelines treffen
- Rolle von Compiler-Scheduling (−O3)

Notizen

Ziel: Datenblätter moderner Kerne architektonisch lesen können — nicht nur Takt und Kerne zählen.

Folie

11/67

Instruction-Level Parallelism (ILP)

- ILP: wie viele Befehle eines Programms *theoretisch* parallel laufen könnten
- Beispiel ohne Abhängigkeit:

```
a = b + c;  
x = y * z;
```


- Unabhängige Operationen → auf getrennten Execution Units im selben Takt denkbar

Notizen

Viele Programme haben unabhängige Teilrechnungen — das ist der Hebel für $IPC > 1$.

Datenabhängigkeiten: RAW

Dieselben IDs. RAW bleibt echt. WAR und WAW sind Namenskonflikte.



Forwarding kuerzt RAW-Wartezeit, hebt die Abhaengigkeit nicht auf.

Ein RAW-Paar hat ILP 1. Das ist nicht das ILP des ganzen Programms.

RV32I/RV64I: 32 Integer-Architekturregister, x0 fest 0. RV32E ist ein anderes Profil.

Architekturregister sind Namen. Die physische Datei kann groesser sein. >100 ist keine Mindestzahl.

Abbildung 3: I1–I3: RAW bleibt, WAR und WAW sind Namenskonflikte auf t0.

- True Dependency / Read-After-Write (RAW): Befehl 2 braucht Ergebnis von Befehl 1

```
add t0, t1, t2    # schreibt t0
sub t3, t0, t4    # liest t0 - muss warten
```

- Dieses Paar hat ILP 1. Das ist keine Aussage über das ganze Programm
- Forwarding verkürzt die Wartezeit und hebt die RAW-Kante nicht auf

Notizen

Bekannt aus MCT1: echte Datenabhängigkeit — Hardware kann Mathematik nicht „wegoptimieren“.

Statisches vs. dynamisches Scheduling

- Statisch (Compiler): Befehle vorab umordnen, Abhängigkeiten auseinanderziehen
- Dynamisch (Hardware): zur Laufzeit unabhängige Befehle finden und an die Units ausgeben (Issue)
- Compiler kennt u. a. Cache-Misses zur Laufzeit nicht → dynamisches Scheduling oft mächtiger

Notizen

Beide Ansätze ergänzen sich; High-End-Kerne verlassen sich stark auf Hardware-Scheduling.

Superskalare Architekturen

- Skalar: typisch ein Issue pro Takt
- Superskalar: Multiple Issue. Das ist noch nicht Out-of-Order
- Fetch-Bytes, Decode, Issue, Ports und Retire-Breite sind verschiedene Größen
- Pipeline wird „breiter“: mehrspurige Autobahn statt einspurigem Fließband

Notizen

Erster Schritt zu $CPI < 1$: Execution Units und Issue-Breite vervielfachen.

Mehrere Execution Units

Vereinfachtes Front-End/Back-End. Breiten sind Annahmen, kein konkreter Kern.



MUL pipelined: Latenz 3 Takte, Initiationsintervall 1. Durchsatz ist nicht 1/Latenz-Wartezeit als Einzelstueck.

Ein MUL alle Takte startbar, Ergebnis erst nach 3 Takten. Latenz und Durchsatz getrennt.

Belegung, ein Takt, drei unabhängige Befehle add/add.lw.

ALU0: add ALU1: add LSU: lw Retire-Slots: 2

Ausführung könnte 3 schaffen, Retire nur 2. Der ROB füllt sich. Engpass: Retire-Breite.

Ein zweites lw im selben Takt passt nicht: nur eine LSU. Operationstyp begrenzt die Auslastung.

Zusätzliche Ports, Scheduler und Bypassnetze kosten Fläche und Energie.

16 Fetch-Bytes sind bei komprimierten RISC-V-Befehlen keine feste Instruktionszahl.

Aktivität alpha, Kapazität C, Spannung V, Frequenz f. Keine feste GHz-Mauer aus diesem Modell.

Abbildung 4: Fetch, Decode, Issue, zwei ALU, eine LSU, Retire 2. Der Engpass ist hier das Retire.

- Zwei Integer-ALU und eine LSU sind das vereinfachte Modell aus der Abbildung
- Ein pipelinierter Multiplizierer trennt Latenz und Initiationsintervall

Notizen

Drei Units reichen nicht für IPC 3. Im Bild begrenzt die Retire-Breite 2 den nachhaltigen Durchsatz, wenn alles andere passt.

Multi-Issue Fetch und Decode

- Fetch holt zum Beispiel 16 Byte. Mit der C-Erweiterung ist das keine feste Instruktionszahl
- Decode prüft Abhängigkeiten *zwischen* den Kandidaten und verteilt auf Units
- Aufwand der Abhängigkeitsprüfung wächst stark mit der Issue-Width

Notizen

Breites Back-End nützt wenig ohne breites Front-End — Decode wird oft zum Flaschenhals.

In-Order Superskalar


- Start-Reihenfolge = Programmreihenfolge (z. B. ältere In-Order-Kerne)
- Unabhängige Nachbarn können gemeinsam starten
- Stoppt ein früher Befehl (Hazard/Miss), stauen dahinter auch Unabhängige

Notizen

Breit, aber starr: ein Stau vorne blockiert freie Units hinten.

Problem: Cache-Miss in-order

Gleiches Programm, gleiche Latenzen. In-Order stoppt hier global hinter dem Load.
 I1 lw Miss, Daten in Takt 4 bereit, Nutzer frühestens Takt 5. ALU-Latenz 1. Retire-Breite OoO: 2.
 In-Order, Issue 1. 7 Takte, 4 Retires, IPC = 4/7 ca. 0,57.



OoO, Issue 2, zwei ALU, eine LSU. 6 Takte, IPC = 4/6 ca. 0,67.



I3 und I4 sind früh fertig, dürfen vor I1 nicht retiren. Der Miss wird überlappt, nicht gelöscht.

Takt 3: beide ALU ungenutzt. Ein voller ROB würde später auch unabhängige Arbeit stoppen.

Werte: mem=10, I2=1, I4=8, I5=3, I7=15, I8=3. Ergebnisse I0=10, I1=11, I3=5, I6=3.

Dieses In-Order-Stauverhalten ist die Lehrannahme, nicht jeder reale In-Order-Kern.

Abbildung 5: Dieselben vier Befehle: in-order 7 Takte, OoO 6 Takte. Der Miss bleibt, Retire wartet.

```
lw  t0, 0(s1)    # Miss → viele Wartezyklen
add t1, t0, t2    # RAW auf t0 → muss warten
sub t4, t5, t6    # unabhängig – trotzdem oft blockiert
```

- Lehrannahme hier: der In-Order-Kern gibt hinter dem wartenden Load nichts weiter aus
- Reale In-Order-Kerne dürfen davon abweichen
- Der Miss bleibt auch bei OoO bestehen. Unabhängige Befehle können ihn nur überlappen

Notizen

Cache-Misses sind Gift für strikte Programmreihenfolge trotz freier ALUs.

Falsche Abhängigkeit: WAW

Write-After-Write:

```
add t0, t1, t2    # schreibt t0
sub t0, t4, t5    # schreibt ebenfalls t0
```

- Keine RAW-Abhängigkeit der Operanden
- Dennoch: Schreibreihenfolge muss erhalten bleiben — sonst falscher Endwert in t0

Notizen

Konflikt nur wegen wiederverwendeten Zielregisters — „falsche“ Abhängigkeit.

Folie

20 / 67

Falsche Abhängigkeit: WAR

Write-After-Read:

```
add t1, t0, t2    # liest t0
sub t0, t4, t5    # überschreibt t0
```

- sub darf t0 nicht zu früh überschreiben, bevor add gelesen hat
- Verhindert unkritische Überholvorgänge ohne weitere Maßnahmen

Notizen

Wieder Register-Recycling: mathematisch unabhängig, architektonisch verkoppelt.

Folie

21 / 67

Engpass: 32 ISA-Register

- RV32I und RV64I: 32 Integerregister $x0-x31$. $x0$ ist fest 0
- Das sind Architektur-Namen, keine physischen Kisten. RV32E hat ein anderes Registerprofil
- Wiederverwendung erzeugt WAR/WAW. Erweiterungen bringen weitere Registerdateien

Notizen

Zu wenige Namen erzeugen falsche Abhängigkeiten. Wie viele physische Register ein Kern hat, steht nicht in der ISA.

Folie

22 / 67

Aufgabe — RAW und Breite

Warum bleibt die Kante von I1 nach I2 bestehen, obwohl I3 und I4 unabhängig sind? Warum folgt aus zwei ALU nicht IPC 2?

Notizen

I2 liest t0, das I1 erst liefert. Das ist RAW. I3 und I4 können den Miss nur überlappen. Die Retire-Breite und der älteste unfertige Befehl begrenzen den Durchsatz. Siehe Abhängigkeitsbild und das

Out-of-Order Execution (OoO)

- Dynamisches Scheduling: blockierte Befehle „parken“
- Unabhängige spätere Befehle dürfen vorgezogen werden
- Issue in datenabhängiger, dynamisch gewählter Reihenfolge. Der Kern bleibt getaktet

Notizen

Modern: nicht mehr nur „nächster PC“ — freie Units mit bereiten Operanden füttern.

Datenfluss-Maschine

- Instruktion „feuert“, wenn Operanden da sind — nicht nur wenn der PC sie erreicht
- Der Miss blockiert die Nutzer des Load. Unabhängige Befehle können vorbeilaufen, bis Issue-Queue oder ROB voll sind
- „Nur Abhängige warten“ gilt nicht ohne diese Grenzen


Notizen

Paradigmenwechsel: vom starren Befehlszeiger zum datengetriebenen Issue.

Drei Phasen der OoO-Pipeline

1. In-Order Front-End: Fetch / Decode
2. Out-of-Order Back-End: Execute
3. In-Order Retire (Commit): Ergebnisse programmgerecht sichtbar machen

Dazwischen: große Puffer (Queues, ROB).



Notizen

Vorne geordnet lesen, Mitte ausnutzen, hinten Ordnung für Software/OS wiederherstellen.

Front-End und Renaming

- Mehrere Befehle aus dem I-Cache holen und dekodieren
- Vor dem Chaos: Register Renaming gegen WAW/WAR
- Architektur-Register der ISA $\neq$ physische Registerdatei

Notizen

32 ISA-Namen bleiben die Illusion für den Compiler — Hardware mappt um.

Register Renaming

- Die ISA-Namen werden auf eine größere physische Datei abgebildet. Eine Zahl über 100 ist kein allgemeines Minimum
- Jeder Befehl mit Ziel außer der festen Null bekommt typisch ein neues physisches Register
- Befehle ohne Ziel und $\times 0$ sind Ausnahmen

Notizen

Genialer Trick: WAW/WAR verschwinden, weil Schreibziele physisch getrennt werden.

Renaming am Beispiel (WAW)

PRF-Modell. Map-Update beim Rename ist nicht der Commit. x0 bekommt kein Ziel.
 Startmap: t0=P0 t1=P1 t2=P2 t3=P3 t4=P4 t5=P5 t6=P6 t7=P7. Frei: P10, P11, P13.

Instr	log. Q	phys. Q	neues Ziel	Map danach	Wert
A add t0,t1,t2	t1,t2	P1,P2	P10	t0→P10	P10=5
B add t3,t0,t4	t0,t4	P10,P4	P13	t3→P13	P13=7
C sub t0,t5,t6	t5,t6	P5,P6	P11	t0→P11	P11=8
E add t1,t0,t2	t0,t2	P11,P2	P14	t1→P14	liest P11
F sub t0,t4,t5	t4,t5	P4,P5	P12	t0→P12	WAR weg

B liest die alte Version P10=5. C schreibt die neue Version P11=8. B sieht P11 nicht.

E liest t0 als P11. F erhaelt ein neues t0=P12. Das ist WAR, kein gemeinsames Ziel.

Freigabe des alten physischen Registers erst nach Commit, wenn kein aelterer Leser bleibt.

Recovery stellt die gueltige Map wieder her. Nicht alle physischen Werte werden geloescht.

Zwei freie ALUs sind zusätzlich noetig. Renaming allein erzwingt kein gemeinsames Issue.

P10/P11 bleiben die Versionsnamen in den folgenden Folien.

Abbildung 6: A schreibt P10, B liest P10, C schreibt P11. E/F zeigen das WAR-Muster.

```
add t0, t1, t2
sub t0, t4, t5
```

Hardware (schematisch):

- add → schreibt P10 (Mapping t0 → P10)
- sub → schreibt P11 (neues Mapping t0 → P11)

Getrennte Ziele erlauben unabhängige Ausführung. Zwei belegte ALU-Ports können das Issue trotzdem verhindern.

Notizen

Namen werden recycelt, physische Kisten sind frisch — ILP gerettet.

Reservation Stations

- Nach Renaming: Befehle in Reservation Stations / Issue Queue
- Klassisch Reservation Stations, alternativ eine gemeinsame Issue Queue. Ein einzelner Common Data Bus ist nur das Lehrbild
- Operand bereit reicht nicht: Unit, Port und Auswahlregel müssen passen

Notizen

Wartehalle: Bordkarte = physische Register; Abflug = Operanden komplett.

Out-of-Order Issue

- Ergebnisse erscheinen auf dem Common Data Bus / Wakeup-Netz
- Wartende Einträge greifen Werte ab; bereite Befehle melden sich
- Scheduler gibt bereite Befehle in freie Units — Reihenfolge $\neq$ Programmzeile

Notizen

Wer Daten hat, rechnet; wer auf Memory wartet, bleibt in der Queue.

Problem: Interrupts im Chaos

- Frühe Befehle noch nicht fertig, spätere schon executed
- Interrupt / Exception: architektonisch sichtbarer Zustand muss konsistent sein
- Ohne Schutz: RAM/Register könnten „Zukunft“ schon enthalten — inkonsistent für OS

Notizen

Betriebssysteme erwarten präzise, geordnete Architektursicht — nicht Zwischenchaos.

Reorder Buffer (ROB)

PRF haelt Werte. ROB haelt Reihenfolge, Ready, Exception und Zielmetadaten. Kein Ergebniszyklinder.

1 juenger fertig I3 ready, I1 nicht. Head zeigt auf I1.	2 aellester fertig I1 ready. I3/I4 bleiben dahinter.	3 Retire Nur der Head retiriert, dann der naechste.	4 Exception I2 fault: kein Commit, juengere verworfen.
--	---	--	---

Architektur vor dem Fault, nach Retire von I1: t0=t0, t1, t3, t6 noch alt.

Nach Squash bleiben diese Architekturwerte. P13/P11 im PRF sind nicht committed.

Synchrone Exception: aeltere duerfen committen, der fehlerhafte Befehl nicht, juengere werden verworfen.

Ein Interrupt ist kein fehlerhafter Befehl. Er wird an einer zulaessigen praезisen Grenze angenommen.

In-order-Retire ordnet die Architektursicht dieses Kerns. Andere Kerne sehen Speicher nicht automatisch so.

RVWMO ist das Speichermodell. Store-Commit, Puffer-Drain und Register-Retire sind verschiedene Schritte.

Issue Queue: Operand bereit reicht nicht. Port, Unit und Auswahl muessen passen.

Ein Common Data Bus ist das klassische Lehrbild. Reale Netze koennen verteilt sein.

OoO heisst datenabhaengige Reihenfolge, nicht eine taktlose CPU.

ROB ist eine verbreitete Loesung fuer praезise Zustaeude, nicht die einzige moegliche Struktur.

Head/Tail, ready und exception stehen im ROB. Der Zahlenwert steht in der PRF.

Abbildung 7: Werte stehen in der PRF. Der ROB merkt sich Ordnung, Ready und Exceptions.

- In diesem PRF-Modell schreibt die ALU in ein physisches Register, nicht in den ROB
- Der ROB führt Reihenfolge, Completion, Exception und Zielmetadaten. Ein result-holding ROB wäre ein anderes, hier nicht verwendetes Modell


Fertige jüngere Befehle stehen in physischen Registern, bis der Head retiriert.

Notizen

Netz mit doppeltem Boden: rechnen darf chaotisch sein — sichtbar werden geordnet.

In-Order Commit (Retire)

Älterer Store, jüngerer Load. Adressalias zuerst unbekannt. Eine Zusatzfolie.



Spekulative Stores dürfen nicht beliebig MMIO auslösen.

Kein Commit heisst nicht: der Cache bleibt ohne Seiteneffekt. Seitenkanäle sind ein anderes Thema.

Unbekannte Aliasbeziehung: der Load wartet oder wird bei Konflikt wiederholt.

Register-Retire und sichtbarer Speicher sind nicht dasselbe Ereignis.

Modellannahme: eine LSU, eine Store-Queue, keine konkrete BOOM-Konfiguration.

Abbildung 8: Store-Queue, Commit und Drain sind drei Schritte. Aliase kann Renaming nicht lösen.

- Retire nur am ältesten noch nicht retired Befehl, bis zur Retire-Breite
- Dadurch wird der Architektur-Registerzustand sichtbar. Ein Store darf danach noch im Puffer stehen
- Andere Beobachter sehen Speicher nach RVWMO, nicht automatisch in dieser Retire-Reihenfolge
- Spätere fertige Einträge warten, auch wenn ihre PRF-Werte schon stehen

Notizen

Programmierer und OS sehen geordnete Semantik — trotz OoO im Back-End.

Exceptions und ROB

- Synchrone Exception: ältere Instruktionen dürfen committen. Die fehlerhafte Instruktion committet ihren normalen Effekt nicht. Jüngere Effekte werden verworfen
- Ein asynchroner Interrupt hat keinen fehlerhaften Befehl. Er wird an einer zulässigen präzisen Grenze angenommen
- Recovery stellt das gültige Mapping wieder her

Notizen

Der Architekturzustand wird präzise. Ein verworfener Store ist nicht dasselbe wie ein unsichtbarer Cache-Seiteneffekt.

Grenzen von OoO

Warum viele Cortex-M / MCU-Kerne ohne OoO bleiben:

- Transistoren: Renaming, Stations, ROB sind teuer
- Energie: ständiges Wakeup/Scheduling kostet — oft Watt statt μW /mW-Regime
- Determinismus: Laufzeiten schwerer vorherzusagen (Hard Real-Time)

Notizen

Königsklasse für Desktop/Phone — für Knopfzellen-Sensoren oft ungeeignet.

Drei Phasen — Kurzfazit

Phase	Ordnung	Aufgabe
Fetch/Decode	in-order	lesen, renaming
Execute	out-of-order	Units auslasten
Commit	in-order	sichtbar machen, Exceptions

Notizen

Anatomie eines High-End-Kerns in einem Satz: geordnet rein, parallel rechnen, geordnet raus.

Aufgabe — Version und Exception

Welche physische Version liest Befehl B? Was bleibt architektonisch gültig, wenn I2 eine synchrone Exception auslöst, nachdem nur I1 retiriert wurde?

Notizen

B liest P10, nicht P11. Nach Retire von I1 ist $t_0 = 10$. I2 committet nicht, I3 und I4 werden verworfen. Ein Interrupt ist davon getrennt: er hat keinen fehlerhaften Befehl. Siehe Rename-Tabelle und ROB-Bild.

Control Hazards

- WAR und WAW kann Renaming entfernen. RAW bleibt. Kontrollfluss ist ein eigener Engpass
- Neuer Engpass: Kontrollfluss (`beq` und andere Branches)
- Beim Fetch des Branch: welcher nächste PC — Fall-through oder Target?
- Entscheidung oft erst nach dem Vergleich in EX (oder später in tiefen Pipelines)

Notizen

Die Pipeline braucht jeden Takt neuen Nachschub — an der Weggabelung fehlt das Vergleichsergebnis noch.

Kosten eines Pipeline-Flush

- Warten auf die ALU: wenige Bubbles — bei 5 Stufen oft erträglich
- Moderne High-Performance-Kerne: deutlich tiefere Pipelines (Größenordnung: viele Stufen), u. a. für hohe Taktraten
- Falscher Weg → Flush vieler spekulativer Instruktionen
- Misprediction Penalty: oft im Bereich vieler Takte — teuer für IPC

Notizen

Tiefe Pipelines erhöhen die Branch Penalty: falsch geraten heißt viele Arbeitseinheiten verwerfen.

Misprediction: Zahlenbeispiel

Annahmen: 20 Prozent Branches, 10 Prozent davon falsch, Penalty 15, Basis-CPI 1. Keine Überlappung.
Aufschlag $0,20 \times 0,10 \times 15 = 0,30$. CPI = 1,30.

Laufzeit * 1,30 30 Prozent länger, gleiches N und f	Durchsatz * 0,769 etwa 23,1 Prozent weniger Durchsatz
--	--

Richtig vorhergesagt	00	01	02	03	04
Falsch	09	01	02	03	04

Ein Treffer ist nicht automatisch kostenlos: Target und Fetch-Bandbreite bleiben.

Die Penalty hängt von Auflösung und Front-End ab, nicht nur von der Stufenzahl.

Renaming entfernt WARWAW, nicht jede Datenabhängigkeit und nicht den Branch.

Die Kurve $CPI = 1 + 0,20 \times m \times 15$ ist ein Modell über die Fehlrate m , keine Messung.

$1/1,30 = 0,76923$. Nicht 23 Prozent länger.

Spekulative Käestchen sind der falsche Pfad und werden verworfen, nicht retired.

Abbildung 9: CPI 1,30 heißt 30 Prozent längere Laufzeit und etwa 23,1 Prozent weniger Durchsatz.

- 20 % der Befehle sind Branches
- Misprediction-Rate 10 %, Penalty 15 Takte
- Basis-CPI = 1 (ideale Pipeline ohne andere Stalls)
- CPI-Aufschlag: $0,20 \times 0,10 \times 15 = 0,30$
- Effektives CPI = 1,30: bei gleichem N und f ist die Laufzeit 30 Prozent länger
- Der Durchsatz sinkt auf $1/1,30 \approx 0,769$, also rund 23,1 Prozent

Notizen

Modell ohne Überlappung: Anteil mal Fehlrate mal Penalty. 1,30 CPI bedeutet 30 Prozent mehr Laufzeit und etwa 23 Prozent weniger Durchsatz. Nicht 23 Prozent länger.

Branch Prediction

- Nicht warten — spekulativ den wahrscheinlichen Weg füllen
- Vorhersage typisch schon beim Fetch
- Ein Treffer vermeidet den Flush, ist aber nicht automatisch kostenlos
- Fehlprognose: Flush / Misprediction Penalty
- Ziel: hohe Accuracy (in der Praxis oft deutlich über 90 %)

Notizen

Glaskugel der Architektur: richtig geraten → Pipeline bleibt voll; falsch → teurer Rollback.

Statische Vorhersage

Einfache fest verdrahtete Heuristiken:

- Rückwärtssprung oft „taken“ (typisch Schleifenende)
- Vorwärtssprung oft „not taken“ (häufig seltene Fehlerpfade)

Hilfreich, aber für sehr tiefe Pipelines oft zu ungenau.

Notizen

90er-Heuristik: hinten = Schleife, vorne = seltenes `if` — gut, aber nicht genug für 15+ Stufen.

Dynamische Vorhersage

- Lernen zur Laufzeit aus der Branch-Historie
- Muster: was zuletzt passierte, passiert oft wieder
- Lange Schleifen: nach wenigen Iterationen fast immer korrektes „taken“

Notizen

Maschinenlernen auf unterster Ebene: pro Sprungstelle Historie im Silizium.

Branch History Table (BHT)

Richtung und Ziel sind getrennt. Index nicht blind die niedrigsten Bits, Ausrichtung beachten.



Aliasing, Index PC[4:2]: 0x04 und 0x24 liefern beide 001.

Zwei verschiedene Branches koennen denselben Eintrag teilen und sich stoeren.

gshare-Lehrbeispiel, 4 Bit: PC-Index 0101 XOR GHR 0011 = 0110.

Globale Historie ist nicht automatisch lokale plus globale Historie.

Lokal, global und Hybrid-Auswahl sind verschiedene Modelle.

TAGE und Perceptron sind veroeffentlichte Beispiele, nicht die Implementierung jedes Kerns.

Lernen heisst hier ein festes Hardware-Modell, keine allgemeine KI.

BHT/PHT: in diesem Bild ist BHT die Richtungstabelle. Das Ziel liegt nur im BTB.

Abbildung 10: Richtung in der BHT, Ziel im BTB. 0x04 und 0x24 aliasen. gshare: 0101 XOR 0011 = 0110.

- Kleiner schneller Speicher (oft SRAM) für Predictions
- Index: typisch untere PC-Bits der Branch-Adresse
- Parallel zum Fetch: Eintrag liefert Taken/Not-Taken-Historie

Notizen

Notizbuch der if-Abfragen: Hausnummer = PC, Eintrag = letztes Verhalten.

1-Bit-Prädiktor


- Ein Bit: zuletzt Taken (1) oder Not Taken (0)
- Schwachpunkt: verschachtelte Schleifen
- Schleifenende kippt auf Not Taken → nächster Eintritt oft sofort falsch geraten
- Zwei Fehlprognosen pro äußerem Durchlauf sind typisch

Notizen

Zu reaktiv: ein Abbruch überschreibt die „Schleifen-Meinung“ zu aggressiv.

2-Bit saturierender Zähler

2-Bit-Automat mit Sättigung. Vorhersage steht im Zustand, Update danach.



T: 00->01, 01->10, 10->11, 11->11. NT: 11->10, 10->01, 01->00, 00->00.

Aus 11 aendert ein NT nur nach 10, Vorhersage bleibt T. Aus 10 reicht ein NT fuer NT.

Folge T T T T N | T T T T N, Start 11. Prediction vor dem Update.

alt	vorh	ist	treffer	neu					
11	T	T	ja	11	10	T	T	ja	11
11	T	T	ja	11	11	T	T	ja	11
11	T	T	ja	11	11	T	T	ja	11
11	T	T	ja	11	11	T	T	ja	11
11	T	N	nein	10	11	T	N	nein	10

Warm, Start stark T: ein Miss je fuerf Ergebnisse, der Schleifenausgang N.

1-Bit, warm auf T: der Ausgang kippt auf N, der naechste Einstieg ist der zweite Miss.

Kaltstart und sehr kurze Schleifen koennen andere Trefferzahlen liefern.

Aufgabe: Start 01, erstes Ergebnis T. Vorhersage ist N, Folgezustand 10. Loesung in den Notizen.

Nachgerechnete Misses in den zehn Schritten ab 11: 2.

Abbildung 11: Vollständiger Automat. Ab Zustand 11 kostet TTTT N genau einen Miss je Durchlauf.

Industrie-Standard: Zustände 00–11

Code	Bedeutung	Vorhersage
00	Strongly Not Taken	Not Taken
01	Weakly Not Taken	Not Taken
10	Weakly Taken	Taken
11	Strongly Taken	Taken

Taken: +1 (Sättigung bei 11); Not Taken: −1 (Sättigung bei 00). Die Selbstschleifen an 00 und 11 stehen im Diagramm.

Notizen

Start im schwachen Not-Taken 01, erstes Ergebnis Taken: Vorhersage Not Taken, Folgezustand 10. Ab stark Taken kostet die Folge T T T T N einen Miss.

Hysteresis des 2-Bit-Zählers

- Lange Schleife → oft 11 (Strongly Taken)
- Einmaliges Ende: 11 → 10 — Vorhersage bleibt Taken
- Nächster Schleifeneintritt: oft sofort korrekt; Zähler steigt wieder
- Aus einem starken Zustand braucht der Wechsel zwei widersprechende Ergebnisse. Aus einem schwachen Zustand genügt eines

Notizen

Trägheit spart Fehlprognosen bei typischen Schleifenabbrüchen.

Branch Target Buffer (BTB)

- Taken allein reicht nicht — Zieladresse muss früh bekannt sein
- Decode/Add für Offset oft zu spät für den nächsten Fetch
- BTB: Cache mit (u. a.) zuletzt beobachteter Target-Adresse
- IF: Prediction + bei Taken sofortiger Target aus dem BTB

Notizen

GPS-Gedächtnis: nicht nur links/rechts, sondern die Zielkoordinaten ohne Wartezeit.

Globale Historie (Korrelation)

- Branches korrelieren oft im C-Kontrollfluss
- Global History Register (GHR): Bitmuster der letzten N Outcomes
- gshare ist ein konkretes Modell: PC-Index XOR globale Historie. Das ist nicht automatisch lokale plus globale Historie
- Erkennt Muster über einzelne Sprungstellen hinweg

Notizen

Nicht nur „dieser `beq`“, sondern „was tat das Programm kurz davor?“.

Fortgeschrittene Prädiktoren

- TAGE und Perceptron-Prädiktoren sind veröffentlichte Beispiele, nicht die Angabe jedes Kerns
- Lernen von Gewichtungen aus der Historie in Hardware
- Praxis: sehr hohe Accuracy bei vielen Workloads — selten, aber teuer bei Misses

Notizen

Die Analogie zum Lernen bleibt im festen Hardware-Modell. Das ist keine allgemeine KI.

Aufgabe — CPI und schwacher Zustand

Was bedeuten CPI 1,30 für Laufzeit und Durchsatz? Der 2-Bit-Zähler steht auf 01, das nächste Ergebnis ist T. Welche Vorhersage gilt?

Notizen

Laufzeitfaktor 1,30, also 30 Prozent länger. Durchsatzfaktor etwa 0,769, also rund 23 Prozent weniger Durchsatz. Zustand 01 sagt Not Taken voraus und geht nach T auf 10. Siehe CPI-Bild und den Automaten.

Spekulative Ausführung

- Spekulativer Fetch braucht kein OoO. Im High-Performance-Modell kommen Prediction und OoO zusammen
- Predictor sagt z. B. „Taken“ → spekulativer Pfad wird gestartet (Issue)
- ALUs rechnen und laden bereits — bevor der Branch architektonisch bestätigt ist

Notizen

Zenit der Performance: rechnen auf Pfaden, die logisch noch unsicher sind.

Rechnen auf Verdacht

- Best Case: Prediction korrekt → Arbeit schon (fast) fertig im ROB
- Speicherlatenzen werden hinter Spekulation versteckt
- IPC kann stark steigen, wenn Units nicht idle auf den Branch warten

Notizen

Während der Branch noch „unterwegs“ ist, läuft der vorhergesagte Pfad schon.

Rollback bei Misprediction

- Falscher Pfad: spekulative Loads/Rechnungen verwerfen
- ROB hält Ergebnisse zurück — kein vorzeitiges Commit in Architekturzustand
- Squash des spekulativen ROB-Teils, dann korrekten Pfad nachfüllen

Notizen

Sicherheitsnetz aus Teil 1: spekulieren darf, sichtbar wird erst nach Bestätigung.

Spectre und Meltdown (2018)

- Lange Annahme: Fehlspekulation sei für Software unsichtbar
- Meltdown: spekulativ über Privilege-Grenzen (z. B. Kernel-Daten) — vor allem bestimmte ältere Designs
- Spectre: spekulativ über fehlvorhergesagte Branches / manipulierte Predictor-Zustände
- Gemeinsam: Architekturzustand wird zurückgerollt — Cache-/Timing-Spuren können bleiben

Notizen

Zwei verwandte, aber unterschiedliche Klassen: Privilege-Bypass (Meltdown) vs. Branch-/Predictor-Missbrauch (Spectre).

Seitenkanal über den Cache

Spectre-v1, schematisch. Die Bounds-Prüfung bleibt architektonisch korrekt.



Architektur Prüfung gilt, falscher Pfad wird verworfen, Register/Map zurueck.

Cache Der abhaengige Probe-Zugriff kann eine Zeile zuruecklassen.

Ein schneller Hit ist ein Indiz mit Rauschen, kein Beweis und keine Messung aus diesem Kurs.

Spectre: falscher vorhergesagter Pfad. Meltdown: andere Privilege-Grenze, vor allem aeltere Designs.

KPTI zielt auf den urspruenglichen Meltdown-Mechanismus, nicht auf jede Spectre-Variante.

Bounds-Masking oder eine passende Barriere kann bestimmte Spectre-v1-Faeile mildern.

Nicht jede Fence ist auf jeder ISA eine Spekulationsbarriere.

Neuere Hardware mindert einzelne Wege. Sie macht nicht jeden Cache-Effekt unsichtbar.

Auch In-Order-Kerne koennen spekulativ fetchen. OoO ist hier zusaetzlich, nicht die einzige Voraussetzung.

Rollback loescht nicht jeden mikroarchitektonischen Zustand und nicht die ganze PRF blind.

Keine Aussage: Spectre ist vollstaendig geloest.

Quellen: spectreattack.com/spectre.pdf und meltdownattack.com/meltdown.pdf.

Abbildung 12: Die Prüfung bleibt korrekt. Der transiente Probe-Zugriff kann die Cache-Spur hinterlassen.

Prinzip (Spectre-artig, stark vereinfacht):

1. Die Bounds-Prüfung bleibt architektonisch korrekt
2. Der vorhergesagte Pfad läuft transient, bevor die Prüfung wirkt
3. Das Geheimnis steuert die Adresse eines folgenden Probe-Zugriffs
4. Squash verwirft den Architekturzustand. Die Cache-Spur kann bleiben

Notizen

Ein schneller Hit ist ein verrauschtes Indiz, kein automatischer Beweis und keine Messung aus dieser Vorlesung.

Timing als Orakel

- Angreifer misst Zugriffszeiten (Flush+Reload / ähnliche Muster)
- Schneller Hit $\Rightarrow$ Zeile war im Cache
- Aus der getroffenen Position lässt sich Information über spekulativ genutzte Werte rekonstruieren
- Klassischer mikroarchitektonischer Side Channel

Notizen

Stoppuhr statt direktem Leserecht — Architektur verbietet, Mikroarchitektur leakt.

Mitigationen

- KPTI zielt vor allem auf den ursprünglichen Meltdown-Mechanismus
- Passendes Bounds-Masking oder eine geeignete Barriere kann bestimmte Spectre-v1-Fälle treffen. Nicht jede Fence ist auf jeder ISA eine Spekulationsbarriere
- Neuere Hardware mindert einzelne Wege und macht nicht jeden Cache-Effekt unsichtbar
- Spectre ist damit nicht vollständig gelöst

Notizen

Patches und Fences kosten Performance; langfristig hilft Silizium-Design.

Ausblick Labor: Compiler hilft der Pipeline

- Hardware kompensiert viel (OoO, BHT) — Compiler kann Hazards und Branches reduzieren
- GCC/Clang: Optimierungsstufen `-O0` ... `-O3`
- Ziel: bessere IPC, weniger Stalls und teure Control Hazards

Notizen

Kein direkter ROB-Zugriff — aber Maschinencode so formen, dass die Pipeline „glücklich“ wird.

Was `-O3` typisch tut

- `-O0` ist zum Debuggen gedacht und keine garantierte Zeile-für-Zeile-Übersetzung
- `-O2` und `-O3` erlauben mehr Analysen. `-O3` garantiert weder Unrolling noch weniger Branches noch kürzere Laufzeit
- Ob eine Schleife ausgerollt wird, hängt von Compiler, Version, `-march` und dem Code ab

Notizen

Derselbe Algorithmus, anderer Assembler — Laufzeit kann stark differieren.

Trick: Instruction Scheduling

- Problem: `lw` → abhängiger Nutzer → Load-Use-Stall
- Compiler schiebt unabhängige Instruktionen in die Lücke (statisches Scheduling)
- C-Reihenfolge $\neq$ optimale Maschinenreihenfolge

Notizen

Blasen in der Pipeline mit nützlicher Arbeit füllen.

Trick: Loop Unrolling

- Enge Schleifen: viele Branches relativ zur Nutzarbeit
- Unrolling: Iterationen ausrollen → weniger `beq`, mehr gerader Code
- Trade-off: größere Code-Größe (I-Cache) vs. weniger Control Hazards

Notizen

Kontrolle gegen Branches — Flash/I-Cache zahlen den Preis.

Tool: Compiler Explorer (Godbolt)

- Web-Tool: C links, Assembler rechts (live)
- Farbzuoordnung C-Zeile → Instruktionen
- Ideal, um `-O1` vs. `-O3` und RISC-V-Output zu vergleichen

Notizen

Röntgenblick für Embedded- und Performance-Entwicklung.

Laboridee: Godbolt und Messung

Geplant (Details im Übungsblatt):

- Godbolt zeigt die Übersetzung, kein OoO-Timing
- Ein Ripes-Vergleich gilt nur für das dort gewählte Pipeline-Modell, nicht für eine Desktop-OoO-CPU
- Renode ohne validiertes Mikroarchitekturmodell belegt keine Stall-, Branch- oder OoO-Zahlen
- Flags, Compilerversion und ABI gehören zur Beobachtung. Siehe Übungsblatt

Notizen

Sehen (Assembler) und messen (Zyklen) — derselbe C-Algorithmus, andere Pipeline-Last.

Zusammenfassung Block 7

- Skalare Pipeline: Ideal oft $IPC \leq 1$
- Superskalar: mehrere Units / Issues pro Takt
- OoO: Renaming + ROB für dynamisches Scheduling und präzise Exceptions
- Branch Prediction (u. a. 2-Bit, BTB): Flushes vermeiden
- Spekulation beschleunigt — Cache-Seitenkanäle (Spectre/Meltdown) als Kehrseite
- Compiler (—O3): Scheduling und Unrolling unterstützen die Hardware

Notizen

Moderne Kerne: vorhersagend, spekulativ, superskalar — Semantik nach außen dennoch „geordnet“.

Evolution: MCT1 → MCT3

- MCT1: klare In-Order-Pipeline, begrenztes ILP
- MCT3 bisher: Caches, DMA, Bus-Mastering
- Heute: physische Register, OoO, Prediction, Spekulation
- Brücke zur realen High-Performance- und zur energieeffizienten MCU-Welt

Notizen

Vom Addierer zum spekulativen Kern — Konzepte von Grund auf aufgebaut.

Folie

67 / 67

Ausblick und Abschluss

- Übungsblatt: Godbolt — -O0/-O3, Scheduling, Unrolling
- Optional: Zyklusvergleich in der Simulation

Vielen Dank — viel Erfolg beim Experimentieren.

Notizen

Quellen, Stand der Vorlesung: RISC-V ISA und RVWMO; BOOM-Pipeline, ROB und LSU als dokumentiertes OoO-Beispiel, nicht als Laborplattform; GCC Optimize-Options; Spectre- und Meltdown-Paper; Ripes und Renode nur in den dort genannten Grenzen. Adressen und Breiten dieser Folien sind das Lehrmodell.

Wer Assembler-Optimierungen lesen kann, programmiert näher an der Hardware. Viel Erfolg!